

# Attention Is All You Need

순환·합성곱 없이 어텐션만으로 시퀀스 변환을 수행하는 Transformer 모델

HAI 논문리딩반 - 5조

## Contents

|       |                                     |   |
|-------|-------------------------------------|---|
| 1     | 연구 배경 및 문제 정의                       | 2 |
| 2     | 핵심 기여 (Contribution)                | 2 |
| 3     | 방법론                                 | 2 |
| 3.1   | Encoder-Decoder 전체 구조               | 2 |
| 3.2   | 어텐션의 세 가지 사용 방식                     | 3 |
| 3.3   | Scaled Dot-Product Attention        | 4 |
| 3.4   | Multi-Head Attention                | 4 |
| 3.5   | Position-wise Feed-Forward Networks | 5 |
| 3.6   | Positional Encoding                 | 5 |
| 3.7   | 임베딩 및 출력 계층의 가중치 공유                 | 5 |
| 3.8   | 훈련 세부사항                             | 6 |
| 3.8.1 | Optimizer 및 학습률 스케줄                 | 6 |
| 3.8.2 | 정규화 기법                              | 6 |
| 4     | 계산 복잡도 비교                           | 6 |
| 5     | 실험 결과                               | 7 |
| 6     | 한계 및 Future Work                    | 7 |

## 1 연구 배경 및 문제 정의

기존의 시퀀스 변환(sequence transduction) 모델은 인코더-디코더 구조의 순환 신경망(RNN, LSTM, GRU)이나 합성곱 신경망(CNN)에 의존해 왔다.

### 기존 순환 모델의 근본적 한계

순환 모델은 시퀀스의 각 위치  $t$ 에서 이전 은닉 상태  $h_{t-1}$ 과 현재 입력을 함수로 하여 새로운 은닉 상태  $h_t$ 를 생성한다. 이러한 **본질적인 순차적 연산 구조**는 다음과 같은 문제를 야기한다:

- 훈련 시 병렬 처리가 원천적으로 불가능하다.
- 긴 시퀀스에서 메모리 제약으로 배치 크기가 제한되어 **심각한 병목**이 발생한다.

한편, 연산 병렬화를 위해 합성곱 신경망을 활용한 모델들(Extended Neural GPU, ByteNet, ConvS2S)도 제안되었으나, 임의의 두 입력·출력 위치의 신호를 연관 짓는 데 필요한 연산량이 거리에 따라 선형적( $O(n)$ ) 또는 대수적( $O(\log n)$ )으로 증가하여 **장기 의존성(long-range dependencies)**을 학습하기 어렵다는 치명적 한계를 지닌다.

### 왜 순차 연산이 병렬화를 막는가?

RNN에서  $h_t = f(h_{t-1}, x_t)$ 이므로,  $h_t$ 를 계산하려면 반드시  $h_{t-1}$ 이 먼저 완료되어야 한다. 시퀀스 길이가  $n$ 이면 최소  $n$ 번의 순차 단계가 필요하며, 이는 GPU의 대규모 병렬 연산 능력을 활용하지 못하게 만든다. 반면 어텐션은 모든 위치 쌍을 **동시에** 계산할 수 있어 순차 단계가  $O(1)$ 이다.

## 2 핵심 기여 (Contribution)

### Transformer의 3대 기여

1. **최초의 순수 어텐션 기반 변환 모델**: 순환(Recurrence)과 합성곱(Convolution)을 완전히 배제하고, 오직 셀프 어텐션(self-attention)에만 의존하는 최초의 시퀀스 변환 모델을 제안하였다.
2. **병렬화 극대화**: 임의의 두 위치 사이를 연결하는 순차적 연산을 상수 시간  $O(1)$ 로 줄여 모델의 병렬화 능력을 극대화하였다.
3. **새로운 SOTA 달성**: 훈련 시간을 대폭 감소시키면서 기계 번역에서 기존 복잡한 구조들을 뛰어넘는 새로운 최고 성능(State-of-the-Art)을 달성하였다.

## 3 방법론

트랜스포머는 인코더와 디코더 스택 모두에 **셀프 어텐션**과 **위치별 완전 연결 계층**(point-wise fully connected layers)을 사용하는 아키텍처를 채택하였다.

### 3.1 Encoder-Decoder 전체 구조

#### 인코더-디코더 스택 구조

인코더는  $N = 6$ 개의 동일한 계층(layer)을 쌓은 스택이다. 각 계층은 두 개의 서브레이어로 구성된다:

1. Multi-Head Self-Attention
2. Position-wise Feed-Forward Network

각 서브레이어에는 잔차 연결(Residual Connection)과 계층 정규화(Layer Normalization)가 적용된다:


$$\text{output} = \text{LayerNorm}(x + \text{Sublayer}(x))$$

이를 위해 모든 서브레이어와 임베딩 계층의 출력 차원은  $d_{\text{model}} = 512$ 로 통일된다.

디코더 역시  $N = 6$ 개의 동일한 계층 스택이며, 인코더의 두 서브레이어에 더해 세 번째 서브레이어—인코더 출력에 대한 Multi-Head Cross-Attention—가 추가된다. 디코더의 모든 서브레이어에도 동일하게 잔차 연결과 계층 정규화가 적용된다.

### Residual Connection이 왜 필요한가?

계층을 깊게 쌓으면 기울기 소실(vanishing gradient) 문제가 발생한다. 잔차 연결은 입력  $x$ 를 서브레이어 출력에 직접 더해줌으로써 기울기가 깊은 계층까지 원활하게 전파되도록 한다. Layer Normalization은 각 계층의 출력 분포를 안정화하여 훈련 수렴 속도를 높인다.



## 3.2 어텐션의 세 가지 사용 방식

트랜스포머에서 Multi-Head Attention은 세 가지 서로 다른 방식으로 사용된다. 각 방식에서 Q, K, V의 출처가 다르다는 점이 핵심이다.

| 위치  | 유형               | Q 출처      | K, V 출처   | 목적                   |
|-----|------------------|-----------|-----------|----------------------|
| 인코더 | Self-Attention   | 인코더 이전 계층 | 인코더 이전 계층 | 입력 토큰 간 관계 포착        |
| 디코더 | Masked Self-Attn | 디코더 이전 계층 | 디코더 이전 계층 | 생성된 토큰 간 관계 (자기회귀)   |
| 디코더 | Cross-Attention  | 디코더 이전 계층 | 인코더 출력    | 입력-출력 정렬 (alignment) |

### 왜 디코더에서 Masking이 필요한가?

디코더는 자기회귀(auto-regressive) 방식으로 토큰을 하나씩 생성한다. 위치  $i$ 의 토큰을 예측할 때 위치  $i+1, i+2, \dots$ 의 미래 토큰 정보가 유입되면 “정답을 미리 보는” 것이 되어 학습이 무의미해진다. 이를 방지하기 위해 어텐션 스코어 행렬에서 미래 위치에 해당하는 값을  $-\infty$ 로 마스킹하여 softmax 후 가중치가 0이 되도록 한다:

$$\text{mask}(i, j) = \begin{cases} 0 & \text{if } j \leq i \\ -\infty & \text{if } j > i \end{cases}$$

### 3.3 Scaled Dot-Product Attention

어텐션 함수는 쿼리(Query), 키(Key), 값(Value)을 하나의 출력으로 매핑하며, 행렬 형태로 묶인  $Q, K, V$ 에 대하여 다음과 같이 계산된다:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

#### Dot-Product Attention vs Additive Attention

어텐션 메커니즘에는 크게 두 가지 방식이 있다:

- **Additive Attention** (Bahdanau): 단일 은닉 계층의 피드포워드 네트워크로 호환성 함수를 계산한다.  $\text{score}(q, k) = v^T \tanh(W_1 q + W_2 k)$
- **Dot-Product Attention**:  $\text{score}(q, k) = q^T k$ 로 단순 내적을 사용한다.

이론적 복잡도는 유사하지만, dot-product는 고도로 최적화된 행렬 곱셈으로 구현할 수 있어 실제로 훨씬 빠르고 메모리 효율적이다. 다만  $d_k$ 가 작을 때는 두 방식의 성능이 비슷하지만,  $d_k$ 가 클 때 스케일링 없는 dot-product는 성능이 열화된다. 이는 내적 값의 크기가 커지면서 softmax가 포화(saturation)되기 때문이며,  $\frac{1}{\sqrt{d_k}}$  스케일링이 이를 해결한다.

#### $\sqrt{d_k}$ 스케일링의 수학적 근거

$q$ 와  $k$ 의 각 성분이 평균 0, 분산 1인 독립 확률변수라고 가정하면, 내적  $q \cdot k = \sum_{i=1}^{d_k} q_i k_i$ 의 평균은 0이고 분산은  $d_k$ 이다.  $d_k = 64$ 이면 내적의 표준편차가 8이 되어 softmax 입력이 극단적으로 커질 수 있다.  $\frac{1}{\sqrt{d_k}}$ 로 나누면 분산이 1로 정규화되어 softmax가 안정적으로 동작한다.

### 3.4 Multi-Head Attention

단일 어텐션 대신, 쿼리·키·값을 서로 다르게 학습된 선형 투영을 통해  $h$ 번 투영하고, 각각에 대해 병렬로 어텐션을 수행한다. 이후 출력값들을 연결(concatenate)하고 다시 투영하여 최종 값을 얻는다:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$

여기서 각 헤드는 다음과 같이 계산된다:

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$

$W_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$ ,  $W_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$ ,  $W_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ ,  $W^O \in \mathbb{R}^{hd_v \times d_{\text{model}}}$ 는 학습 가능한 파라미터 행렬이다.

### 왜 Multi-Head 인가? — 단일 어텐션과의 차이

단일 어텐션은 하나의 관점에서만 토큰 간 관계를 포착한다. Multi-Head Attention은 서로 다른 부분공간(subspace)에서 **다양한 유형의 관계**(구문적, 의미적, 위치적 등)를 동시에 학습할 수 있다. 논문에서는  $h = 8$  개의 헤드를 사용하며, 각 헤드의 차원은  $d_k = d_v = d_{\text{model}}/h = 64$ 로 설정하여 단일 어텐션과 총 연산량이 유사하도록 하였다.

### 3.5 Position-wise Feed-Forward Networks

인코더와 디코더의 각 계층에는 개별 위치마다 독립적이고 동일하게 적용되는 완전 연결 피드포워드 네트워크가 포함된다. 이는 두 개의 선형 변환과 그 사이의 ReLU 활성화 함수로 구성된다:

$$\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

내부 차원은  $d_{\text{ff}} = 2048$ 이며, 입출력 차원은  $d_{\text{model}} = 512$ 이다. 이는 커널 크기 1인 합성곱 두 번과 동일한 연산으로 해석할 수 있다.

### 3.6 Positional Encoding

순환 및 합성곱 연산이 없으므로 시퀀스 내 토큰의 위치 정보를 주입하기 위해, 다양한 주파수를 가지는 사인(sine) 및 코사인(cosine) 함수 기반의 위치 인코딩을 입력 임베딩에 더해준다:

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \quad (1)$$

$$PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \quad (2)$$

여기서  $pos$ 는 시퀀스 내 위치,  $i$ 는 차원 인덱스이다.

### 왜 사인·코사인 함수를 사용하는가?

사인·코사인 함수를 선택한 핵심 이유는 **상대적 위치를 선형 변환으로 표현**할 수 있기 때문이다. 임의의 고정 오프셋  $k$ 에 대해  $PE_{pos+k}$ 는  $PE_{pos}$ 의 선형 함수로 나타낼 수 있으므로, 모델이 상대적 위치 관계를 쉽게 학습할 수 있다. 또한 학습 데이터에 등장하지 않은 더 긴 시퀀스에도 자연스럽게 외삽(extrapolation)이 가능하다.

### 3.7 임베딩 및 출력 계층의 가중치 공유

트랜스포머에서는 세 곳의 가중치가 공유된다:

- 인코더 입력 임베딩 (Input Embedding)
- 디코더 입력 임베딩 (Output Embedding)
- 디코더 최종 Linear 계층 (pre-softmax)

이 세 계층이 동일한 가중치 행렬을 공유하며, 임베딩 계층에서는 가중치에  $\sqrt{d_{\text{model}}}$ 을 곱하여 사용한다.

### 왜 임베딩에 $\sqrt{d_{\text{model}}}$ 을 곱하는가?

임베딩 벡터의 각 성분은 일반적으로 작은 값으로 초기화되므로, 차원이 높을수록 벡터의 L2 노름이 상대적으로 작아진다.  $\sqrt{d_{\text{model}}}$ 을 곱하면 임베딩 벡터의 스케일이 Positional Encoding과 비슷한 크기가 되어, 위치 정보가 임베딩 정보를 압도하거나 그 반대가 되는 것을 방지한다.

### 3.8 훈련 세부사항

#### 3.8.1 Optimizer 및 학습률 스케줄

Adam optimizer ( $\beta_1 = 0.9$ ,  $\beta_2 = 0.98$ ,  $\epsilon = 10^{-9}$ )를 사용하며, 다음의 warmup 학습률 스케줄을 적용한다:

$$lr = d_{\text{model}}^{-0.5} \cdot \min(\text{step}^{-0.5}, \text{step} \cdot \text{warmup\_steps}^{-1.5})$$

이 스케줄은 처음 warmup\_steps (= 4000) 동안 학습률을 선형으로 증가시킨 뒤, 이후 스텝 수의 역제곱근에 비례하여 감소시킨다.

#### Warmup이 왜 필요한가?

훈련 초기에는 파라미터가 무작위에 가까워 기울기의 분산이 크다. 이때 큰 학습률을 적용하면 불안정한 업데이트가 발생할 수 있다. Warmup은 초기에 학습률을 점진적으로 올려 파라미터가 합리적인 영역에 도달한 후 본격적인 학습을 시작하게 한다. 이후 감소하는 스케줄은 수렴 단계에서 세밀한 조정을 가능하게 한다.

#### 3.8.2 정규화 기법

#### Transformer의 3가지 정규화

1. **Residual Dropout:** 각 서브레이어의 출력에 잔차 연결 전 dropout ( $P_{\text{drop}} = 0.1$ )을 적용한다. 임베딩과 위치 인코딩의 합에도 동일하게 적용한다.
2. **Attention Dropout:** 어텐션 가중치(softmax 출력)에도 dropout을 적용한다.
3. **Label Smoothing** ( $\epsilon_{ls} = 0.1$ ): 정답 레이블을 one-hot 대신  $(1 - \epsilon_{ls})$ 의 확률을 정답에, 나머지를 균등 분배한다. 이는 perplexity를 약간 악화시키지만 BLEU 점수와 정확도를 향상시킨다.

## 4 계산 복잡도 비교

트랜스포머가 기존 방법론보다 우수한 이유를 직관적으로 이해하기 위해, 계층당 계산 복잡도·순차 연산 수·최대 경로 길이를 비교한다.

| 계층 유형                  | 계층당 복잡도                  | 순차 연산 수 | 최대 경로 길이      |
|------------------------|--------------------------|---------|---------------|
| Self-Attention         | $O(n^2 \cdot d)$         | $O(1)$  | $O(1)$        |
| Recurrent (RNN)        | $O(n \cdot d^2)$         | $O(n)$  | $O(n)$        |
| Convolutional          | $O(k \cdot n \cdot d^2)$ | $O(1)$  | $O(\log_k n)$ |
| Self-Attn (restricted) | $O(r \cdot n \cdot d)$   | $O(1)$  | $O(n/r)$      |

#### 이 표를 어떻게 읽는가?

- 순차 연산 수는 병렬화 가능성을 결정한다. Self-Attention은  $O(1)$ 이므로 모든 위치를 동시에 처리할 수 있다. RNN은  $O(n)$ 이므로 시퀀스 길이만큼 순차적으로 처리해야 한다.
- 최대 경로 길이는 장기 의존성 학습 난이도를 결정한다. 임의의 두 위치 사이 신호가 거쳐야 하는 최대 단계 수로, Self-Attention은  $O(1)$ —어떤 두 토큰이든 한 번의 어텐션으로 직접 연결된다.
- $n$ : 시퀀스 길이,  $d$ : 표현 차원,  $k$ : 합성곱 커널 크기,  $r$ : 제한된 어텐션의 이웃 크기.

## 5 실험 결과

| 모델                       | EN-DE BLEU  | EN-FR BLEU  |
|--------------------------|-------------|-------------|
| 기존 SOTA (앙상블 포함)         | 26.4 이하     | 41.0 이하     |
| Transformer (base)       | 27.3        | 38.1        |
| <b>Transformer (big)</b> | <b>28.4</b> | <b>41.8</b> |


### 핵심 실험 수치

- **WMT 2014 EN-DE:** Transformer (big) 가 28.4 BLEU를 달성하여 기존 최고 모델 및 앙상블 결과를 **2.0 BLEU 이상 상회**하며 새로운 SOTA를 기록하였다.
- **WMT 2014 EN-FR:** 41.8 BLEU를 달성하여 기존 모든 단일 모델의 성능을 넘어섰으며, 이전 최고 모델 훈련 비용의 **1/4 미만**으로 달성되었다.
- **훈련 효율성:** 기본 모델(base)조차  $3.3 \times 10^{18}$  FLOPs만으로 기존 경쟁 모델(GNMT+RL 앙상블의  $1.8 \times 10^{20}$  FLOPs 등)을 상회하였다.
- **일반화 성능:** 영어 구문 분석(English constituency parsing)에서 4-layer 모델 기준 WSJ 91.3 F1, 반지도 학습 환경에서 92.7 F1을 기록하여 RNN 기반 모델을 능가하였다.

## 6 한계 및 Future Work

- **셀프 어텐션의 이차 복잡도:** 시퀀스 길이  $n$ 이 표현 차원  $d$ 보다 작은 경우에는 효율적이지만, 시퀀스 길이가 매우 긴 작업에서는 셀프 어텐션의 계산 복잡도가  $O(n^2 \cdot d)$ 로 증가한다.
- **제한된 셀프 어텐션:** 이를 극복하기 위해 출력 위치 주변의 크기  $r$ 인 이웃만 고려하는 제한된(restricted) 셀프 어텐션 방식을 향후 연구로 제안하였다.
- **멀티모달 확장:** 텍스트 이외의 이미지, 오디오, 비디오 등 다양한 입출력 모달리티를 다루는 문제로의 확장을 제시하였다.
- **비순차적 생성:** 데이터 생성 과정의 순차적 특성을 줄여 더욱 병렬적인 생성이 가능하도록 만드는 것을 Future Work로 제시하였다.

## Summary



### 전체 흐름 요약

Transformer는 순환·합성곱 없이 **셀프 어텐션**만으로 시퀀스 변환을 수행하는 최초의 모델이다. Scaled Dot-Product Attention을 기반으로 Multi-Head 구조를 통해 다양한 관점의 관계를 병렬로 포착하며, 위치 인코딩으로 순서 정보를 보완한다. 결과적으로 기계 번역에서 기존 SOTA를 크게 상회하는 성능을 훨씬 적은 훈련 비용으로 달성하였다.