

Parcae: Scaling Laws For Stable Looped Language Models

반복 계층의 불안정성을 동적 시스템으로 규명하고,
스펙트럼 노름 제약으로 안정화한 예측 가능한 스케일링 아키텍처

HAI 논문리딩반 – 5조

Zachary Novack, Taylor Berg-Kirkpatrick, Daniel Y. Fu
UC San Diego & Together AI (arXiv:2604.12946, Apr 2026)

Contents

1	연구 배경 및 문제 정의	2
2	핵심 기여 (Contribution)	2
3	방법론	2
3.1	Parcae 아키텍처 구조	2
3.2	동적 시스템 재해석	3
3.3	LTI 안정성 분석	3
3.4	안정적 파라미터화 (Stable Parameterization)	4
3.5	학습 안정화 기법	4
3.5.1	Prelude Normalization	4
3.5.2	Per-Sequence Depth Sampling	4
3.5.3	Truncated Backpropagation Through Depth	4
3.6	학습 목적 함수	5
3.7	최종 순전파 구조	5
3.8	스케일링 법칙	5
3.8.1	Training Scaling Law (학습 파워 법칙)	5
3.8.2	Test-Time Scaling Law (테스트 시 포화 법칙)	5
3.8.3	Unified Scaling Law (통합 스케일링 법칙)	6
4	실험 결과	6
4.1	품질 향상: 기존 RDM 베이스라인 대비	6
4.2	품질 향상: 순수 트랜스포머 대비	6
4.3	파라미터 효율성	6
4.4	스케일링 법칙 검증	7
4.4.1	Training Law	7
4.4.2	IsoFLOP 비교: Looping vs Fixed-Depth	7
4.4.3	Unified Test-Time Law	7
5	한계 및 Future Work	7

1 연구 배경 및 문제 정의

파라미터 수와 학습 데이터를 함께 늘려 품질을 향상시키는 기존의 방식은 모델의 깊이와 너비를 기하급수적으로 키워 메모리 사용량을 크게 팽창시킨다. 이에 대한 대안으로 활성화 값(activations)을 블록 계층에서 반복시키는 계층 반복(layer-looped) 모델이 제안되었다.

계층 반복 모델의 핵심 문제

1. 잔차 상태 폭발(Residual State Explosion): 반복 계층에서 잔차 스트림의 값이 반복 횟수에 따라 기하급수적으로 증가하여 학습이 발산한다.
2. 급격한 손실 값 상승(Loss Spikes): 학습 중 갑작스러운 손실 값 폭등이 발생하여 안정적인 수렴이 불가능하다.
3. 불안정성 원인 분석 부재: 복잡한 비선형 아키텍처로 인해 불안정성의 근본 원인을 해석학적으로 파악하기 어렵다.

기존 해결 시도의 한계

기존에는 민감한 하이퍼파라미터 조율이나 사후 정규화(Post-Norm) 기법에 의존했으며, 추론 시 확장성을 위해 학습 중 무작위 가변 깊이(stochastic depth)를 사용할 때에도 여전히 손실 값 상승 현상이 관찰되었다. 이는 문제의 근본 원인을 해결하지 못한 채 증상만 완화하는 접근이었다. Parcae는 안정성이 적절히 제어되면 잔차 정규화(residual normalization) 자체가 불필요함을 보인다.

2 핵심 기여 (Contribution)


Parcae의 4대 기여

1. 동적 시스템을 통한 불안정성 규명: 반복 계층 구조를 잔차 스트림에 대한 비선형 시변 동적 시스템으로 수식화하고, 선형 근사를 통해 상태 발산의 원인이 주입 파라미터의 지나치게 큰 스펙트럼 노름(spectral norm) 때문임을 수학적으로 규명하였다.
2. Parcae 아키텍처 제안: 스펙트럼 노름을 1 미만으로 안전하게 제약하기 위해 주입 파라미터를 음의 대각 파라미터화(negative diagonal parameterization)하고 이산화한 안정적 구조를 제안하였다.
3. 안정적 학습 알고리즘 도입: 반복 유닛 입력 전 정규화(Prelude normalization)와 시퀀스 단위 깊이 샘플링(per-sequence depth sampling)을 도입하여 학습 안정성을 확보하였다.
4. 반복 스케일링 법칙 도출: 반복 연산을 데이터 및 파라미터 규모와 독립적인 직교 스케일링 축으로 정의하고, 학습/테스트 시 연산 확장에 대한 통합 스케일링 법칙을 도출하였다.

3 방법론

3.1 Parcae 아키텍처 구조

Parcae는 세 개의 블록으로 구성된다: 서곡(Prelude, $\mathcal{P}$), 반복(Recurrent, $\mathcal{R}$), 종결(Coda, $\mathcal{C}$).



각 블록의 역할

- **Prelude $\mathcal{P}$:** 입력 시퀀스를 초기 임베딩으로 변환하고, Layer Normalization을 적용하여 반복 유닛에 안정적인 입력을 제공한다.
- **Recurrent $\mathcal{R}$:** 핵심 반복 블록으로, 동적 시스템 기반의 안정적 상태 업데이트를 T 회 수행한다.
- **Coda $\mathcal{C}$:** 최종 은닉 상태 h_T 를 디커플링 행렬 $\mathbf{C}$ 로 변환한 뒤 projection head를 통해 출력을 생성한다.

3.2 동적 시스템 재해석

기존의 반복 블록 업데이트 연산 $h_{t+1} = R(h_t, e)$ 를 선형 상태 행렬을 포함하는 비선형 시변 동적 시스템으로 재구성한다:

$$h_{t+1} = \bar{A}h_t + \bar{B}e + \bar{R}(h_t, e)$$

수식의 각 항 해설

- $\bar{A}h_t$: 이전 잔차 상태의 **기억(memory)** 항. $\bar{A}$ 의 크기가 상태 유지 정도를 결정한다.
- $\bar{B}e$: 입력 임베딩 e 가 잔차 스트림에 미치는 **주입(injection)** 항.
- $\bar{R}(h_t, e)$: 비선형 변환 블록(Attention, FFN 등)의 기여분.

3.3 LTI 안정성 분석

비선형 블록 $\bar{R}$ 을 제외하고 선형화된 이산 LTI(Linear Time Invariant) 시스템을 분석한다:

$$h_{t+1} = \bar{A}h_t + \bar{B}e$$

정의 3.1 (BIBO 안정성 조건). 위 시스템이 유계 입력에 대해 유계 출력(Bounded-Input Bounded-Output)을 보장하려면, 행렬 $\bar{A}$ 의 스펙트럼 반경이 다음을 만족해야 한다:

$$\rho(\bar{A}) < 1$$

기존 방법이 불안정한 이유

기존 계층 반복 모델에서 잔차 연결(residual connection)의 주입 방식을 동적 시스템 관점에서 분석하면:

- **Addition injection:** $\bar{A} = I$ (항등 행렬)로, $\rho(\bar{A}) = 1$ 이므로 **한계 안정(marginally stable)** — 비선형 항의 작은 섭동에도 발산 가능.
- **Concatenation injection:** $\bar{A}$ 가 제약 없이 학습되므로 $\rho(\bar{A}) > 1$ 이 될 수 있어 **불안정(unstable)**.

Parcae는 $\rho(\bar{A}) < 1$ 을 구조적으로 보장하여 이 문제를 근본적으로 해결한다.

3.4 안정적 파라미터화 (Stable Parameterization)

Parcae는 학습 가능한 시간 간격 변수 $\Delta \in \mathbb{R}^{d_h}$ 를 이용하여 A 와 B 를 이산화하며, 특히 A 행렬이 $\rho(\bar{A}) < 1$ 을 구조적으로 충족하도록 다음과 같이 음의 대각 행렬로 명시적 제약을 가한다:

$$A := \text{Diag}(-\exp(\log_A))$$

이산화(ZOH/Euler 혼합)를 적용하면:

$$\bar{A} = \exp(\Delta \cdot A), \quad \bar{B} = \Delta \cdot B$$

왜 음의 대각 행렬인가?

A 의 모든 대각 원소가 음수이므로 $\exp(\Delta \cdot A)$ 의 모든 원소는 $(0, 1)$ 구간에 놓인다. 따라서 $\bar{A}$ 는 대각 행렬이고 모든 고유값의 절대값이 1 미만이므로, $\rho(\bar{A}) < 1$ 이 **학습 과정 전체에서 구조적으로 보장된다**. 이는 SSM(State Space Model) 계열의 안정적 파라미터화 기법에서 영감을 받은 설계이다.

3.5 학습 안정화 기법

3.5.1 Prelude Normalization

반복 유닛에 입력되기 전에 Layer Normalization을 적용하여 입력 스케일을 안정화한다:

$$e = \text{LN}(\mathcal{P}(s))$$

3.5.2 Per-Sequence Depth Sampling

추론 시 다양한 반복 횟수에 대응하기 위해 학습 중 무작위 깊이를 사용하되, **마이크로 배치 단위가 아닌 시퀀스 단위로** 깊이를 샘플링한다.

왜 시퀀스 단위 샘플링인가?

마이크로 배치 단위로 깊이를 샘플링하면, 같은 배치 내의 모든 시퀀스가 동일한 반복 횟수를 갖게 되어 그래디언트 추정치의 분산이 커진다. 시퀀스 단위 샘플링은 하나의 배치 내에서 다양한 반복 횟수가 공존하게 하여 그래디언트의 분산을 줄이고, 손실 값 상승(loss spikes)을 효과적으로 억제한다.

3.5.3 Truncated Backpropagation Through Depth

메모리 효율을 위해 역전파 깊이를 전체 반복 횟수보다 짧게 제한한다. 논문에서는 다음과 같이 설정한다:

$$\mu_{\text{bwd}} = \left\lceil \frac{\mu_{\text{rec}}}{2} \right\rceil$$

즉, 평균 반복 횟수의 절반만큼만 그래디언트를 역전파하고, 나머지 초기 반복은 no_grad로 처리한다.

Truncated BPTT의 설계 근거

- μ_{bwd} 를 μ_{rec} 보다 작게 설정하면 메모리 사용량이 μ_{bwd} 에 비례하여 제한된다.
- 그러나 μ_{bwd} 가 너무 작으면 높은 반복 횟수에서의 테스트 시 일반화가 저하된다 (Appendix I ablation).
- $\mu_{\text{bwd}} = \lceil \mu_{\text{rec}}/2 \rceil$ 은 메모리 효율과 일반화 성능 사이의 최적 균형점으로 실험적으로 확인되었다.

3.6 학습 목적 함수

Parcae의 학습 목적 함수는 데이터셋과 가변 깊이 분포 Λ 양쪽에 대한 기대값을 최소화한다:

$$\theta^* = \arg \min_{\theta} \mathbb{E}_{(x,y) \sim \mathcal{D}, T \sim \Lambda(\mu_{\text{rec}})} [\ell(f_{\theta}(x; T), y)]$$

여기서 Λ 는 평균 μ_{rec} 인 Poisson 분포이며, 각 시퀀스마다 독립적으로 T 를 샘플링한다. 이 목적 함수가 per-sequence depth sampling의 이론적 근거이다: 배치 내에서 더 많은 깊이를 샘플링할수록 Λ 에 대한 기대값 추정이 정확해진다.

3.7 최종 순전파 구조

Parcae의 완전한 순전파 과정을 정리하면:

$$e = \text{LN}(\mathcal{P}(s)) \tag{1}$$

$$h_0 \sim \mathcal{N}(0, \sigma^2 I_{d_h \times d_h}) \tag{2}$$

$$h_{t+1} = \bar{A} h_t + \bar{B} e + \bar{\mathcal{R}}(h_t, e), \quad t = 0, 1, \dots, T-1 \tag{3}$$

$$p = \mathcal{C}(\mathbf{C} h_T) \tag{4}$$

여기서 T 는 반복 횟수, $\mathbf{C} \in \mathbb{R}^{d_c \times d_h}$ 는 $\mathcal{C}$ 와 $\mathcal{R}$ 의 임베딩 차원을 디커플링하는 행렬, $\mathcal{C}$ 는 projection head이다.

h_0 초기화와 Path Independence

h_0 를 가우시안 노이즈로 초기화하는 설계는 Deep Equilibrium Model(DEQ)의 **path independence** 개념에서 차용되었다. 충분한 반복 후 시스템이 고정점(fixed point)에 수렴한다면, 초기 상태의 선택이 최종 출력에 미치는 영향이 사라진다. 이는 h_0 를 학습 가능한 파라미터로 두지 않아도 되는 이론적 근거를 제공한다.

3.8 스케일링 법칙

3.8.1 Training Scaling Law (학습 파워 법칙)

Chinchilla 스타일의 파라메트릭 피팅을 반복 모델에 확장한다. 유효 파라미터 수 $\mathbf{N}(\mu_{\text{rec}})$ (루프를 풀었을 때의 파라미터)와 학습 토큰 수 D 에 대해:

$$\hat{\mathcal{L}}_{\text{train}}(\mu_{\text{rec}}, D) = E + X \cdot \mathbf{N}(\mu_{\text{rec}})^{-x} + Y \cdot D^{-y}$$

이 함수는 isoFLOP 실험 데이터에 Huber loss + L-BFGS로 피팅된다.

3.8.2 Test-Time Scaling Law (테스트 시 포화 법칙)

테스트 시 반복 횟수 T 를 늘릴 때의 손실 감소는 포화 지수 감소(saturating exponential decay)를 따른다:

$$\mathcal{L}(T) = \mathcal{L}_{\infty} + Z \cdot e^{-z \cdot T}$$

여기서 $\mathcal{L}_{\infty}$ 는 환원 불가능한 손실 하한으로, $T = \mu_{\text{rec}}$ 에서의 학습 손실과 거의 일치한다.

3.8.3 Unified Scaling Law (통합 스케일링 법칙)

위 두 법칙을 결합하여, 학습 조건(μ_{rec}, D)과 테스트 조건(T)을 동시에 포괄하는 단일 함수를 도출한다:

$$\hat{\mathcal{L}}_{\text{unified}}(T \mid \mu_{\text{rec}}, D) = \underbrace{E + X \cdot N(\mu_{\text{rec}})^{-x} + Y \cdot D^{-y}}_{\text{Training Law Floor } \hat{\mathcal{L}}_{\text{train}}} + \underbrace{Z \cdot \exp\left(-\frac{z \cdot T}{\mu_{\text{rec}}}\right)}_{\text{Test-Time Decay}}$$

통합 스케일링 법칙의 각 항 해설

- E : 환원 불가능한 손실(irreducible loss). 데이터 자체의 엔트로피 하한.
- $X \cdot N(\mu_{\text{rec}})^{-x}$: 유효 파라미터 규모에 의한 손실 감소. μ_{rec} 가 클수록 유효 파라미터가 증가.
- $Y \cdot D^{-y}$: 학습 데이터 규모에 의한 손실 감소.
- $Z \cdot \exp(-z \cdot T/\mu_{\text{rec}})$: 테스트 시 반복 비율 T/μ_{rec} 에 따른 포화 감소. Training law가 바닥(floor)을 설정하고, 추가 반복이 이 바닥에 지수적으로 접근한다.

왜 T/μ_{rec} 비율인가?

감쇠율이 $-z \cdot T/\mu_{\text{rec}}$ 로 정규화되는 이유는, 학습 시 더 깊은 반복(μ_{rec} 큼)으로 훈련된 모델일수록 테스트 시에도 더 많은 반복이 필요하기 때문이다. 즉, 학습 깊이가 테스트 시 스케일링의 “천장”을 결정한다. 이는 제어 이론에서 안정 이산 시스템의 상태 노름이 스펙트럼 반경에 의해 지수적으로 수렴하는 것과 일맥상통한다.

4 실험 결과

4.1 품질 향상: 기존 RDM 베이스라인 대비

파라미터와 학습 데이터 양을 맞춘 기존의 반복 깊이 모델(RDMs)과 비교한 결과:

평가 지표	Parcae 개선폭
검증 퍼플렉서티 (Validation PPL)	최대 6.3% 감소
WikiText PPL	9.1% 향상

4.2 품질 향상: 순수 트랜스포머 대비

파라미터 수를 일치시킨 트랜스포머 모델과 비교 (1.3B 파라미터, 100B 토큰 학습):

벤치마크	1.3B Parcae	1.3B Transformer	차이
Core	28.44 ± 0.28	25.45 ± 0.08	+2.99 pt
Core-Extended	—	—	+1.18 pt

4.3 파라미터 효율성

핵심 효율성 수치

- **770M Parcae $\approx$ 1.3B Transformer**: 770M 파라미터의 Parcae 모델이 1.3B 트랜스포머와 거의 동일한 품질을 달성.
- **Core 평가**: 23.3–87.5% 더 나은 파라미터 효율성.
- **Core-Extended 평가**: 29.9–58.2% 더 나은 파라미터 효율성.

4.4 스케일링 법칙 검증

4.4.1 Training Law

한정된 예산 내에서 최적의 반복 깊이 μ_{rec} 와 훈련 토큰 수는 일관된 지수를 갖는 파워 법칙을 따른다:

$$\mu_{\text{rec}}^* \propto C^{\gamma_\mu}, \quad \gamma_\mu \approx 0.40 \quad D^* \propto C^{\gamma_D}, \quad \gamma_D \approx 0.78$$

이는 FLOP 예산 C 가 증가할 때, 반복 깊이와 데이터를 **함께(tandem)** 늘려야 최적임을 의미한다.

4.4.2 IsoFLOP 비교: Looping vs Fixed-Depth

동일 FLOP 예산에서 최적 μ_{rec}^* 로 학습한 Parcae는 고정 깊이($\mu_{\text{rec}} = 1$) 모델 대비 엄격히 낮은 손실을 달성하며, 이는 Core 벤치마크에서 **1.2–2.0 포인트** 차이로 나타난다.

4.4.3 Unified Test-Time Law

스케일링 예측 정확도


조건	예측 오차율
Test-Time OOD (보지 못한 세팅)	0.85–1.31%
Oracle (기준 학습 손실 제공)	0.10–0.17%

통합 파라메트릭 피팅이 보지 못한 평가 세팅에서도 경험적 손실 값을 1.31% 이내의 오차로 정확히 예측한다. Oracle 조건에서 오차가 0.17% 이하로 떨어지는 것은, 잔여 오차의 대부분이 training law의 $\sim 1\%$ 외삽 오차에서 기인함을 확인해준다.

5 한계 및 Future Work

- **아키텍처 및 규모의 한계:** 설계 및 파워 법칙의 유효성이 최대 1.3B 파라미터 수준에 한정되어 있다. 거대 모델에서도 스케일링 특성이 유지되는지 확인이 필요하다.
- **반복 구조의 탐색 범위:** 블록 내 계층 단위의 최적 배치, 서로 다른 아키텍처 간의 혼합 구성, 극단적으로 깊은 반복 횟수(extreme looping) 하에서의 학습 성능에 대한 대규모 후속 탐색이 유망하다. 동적 시스템 프레임워크 내에서 다른 이산화 방식, full-rank 파라미터화, 다른 업데이트 규칙도 탐색 대상이다.
- **추론 지연 문제:** 훈련에 사용된 평균 반복 횟수(μ_{rec})를 늘리면 모델 품질이 향상되지만, 추론에 필요한 테스트 시스템 횟수도 정비례하여 증가한다. 추론 시간을 절감하면서 품질을 유지하는 효율화 기술 연구가 필수적이다.
- **직교 축 간 상호작용:** 파라미터, 데이터, 반복이라는 세 직교 축을 동시에 효율적으로 스케일링하는 방법에 대한 연구가 남아 있다.

Summary



전체 흐름 요약

Parcae는 계층 반복 모델의 불안정성을 비선형 시변 동적 시스템으로 재해석하여 스펙트럼 노름 $\rho(\bar{A}) \geq 1$ 이 근본 원인임을 규명하고, 음의 대각 파라미터화로 $\rho(\bar{A}) < 1$ 을 구조적으로 보장하는 아키텍처를 제안하였다. Prelude normalization과 per-sequence depth sampling으로 학습을 안정화하여, 770M 모델이 1.3B Transformer에 필적하는 파라미터 효율성을 달성하고, 반복 연산에 대한 예측 가능한 통합 스케일링 법칙(오차 $\leq 1.31\%$)을 도출하였다.