

DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models

고품질 수학 코퍼스 120B 토큰과 GRPO 강화학습으로
외부 도구 없이 MATH 51.7%를 달성한 7B 오픈소스 모델

HAI 논문리딩반 - 5조

Contents

1	연구 배경 및 문제 정의	2
2	핵심 기여 (Contribution)	2
3	방법론	2
3.1	데이터 파이프라인	2
3.2	GRPO 최적화 알고리즘	3
3.2.1	GRPO 학습 루프	3
3.2.2	PPO와의 구조적 비교	4
3.2.3	GRPO 목적 함수	4
3.2.4	보상 함수 설계	5
4	실험 결과	5
4.1	주요 벤치마크 성능	5
4.2	사전 학습 코퍼스 품질 비교	6
5	한계 및 Future Work	6

1 연구 배경 및 문제 정의

대형 언어 모델(LLM)이 수학적 추론 능력을 크게 향상시켰으나, GPT-4나 Gemini-Ultra와 같은 최고 수준의 모델들은 비공개이며 기존 오픈소스 모델들은 성능 면에서 크게 뒤쳐져 있다.

두 가지 핵심 문제

1. **고품질 수학 데이터 부족:** 수학적 사전 학습에 주로 사용되는 arXiv 데이터는 모델의 수학적 추론 성능 향상에 큰 효과가 없는 것으로 나타났다. 양질의 대규모 수학 훈련 데이터를 어떻게 수집하고 정제할 것인가가 중요한 과제였다.
2. **PPO의 구조적 비효율:** LLM 성능 향상을 위해 널리 사용되는 강화학습 방법론인 PPO(Proximal Policy Optimization)는 정책 모델(Policy Model)과 크기가 비슷한 **가치 모델(Critic/Value Model)**을 동시에 학습해야 하므로, 메모리 소비와 계산 자원 부담이 크다.

왜 arXiv 데이터가 효과적이지 않은가?

arXiv 논문은 고도로 형식화된 수학 표현을 포함하지만, 실제 수학 문제 풀이에 필요한 **단계별 추론 과정(step-by-step reasoning)**이 부족하다. 논문은 결과와 증명을 압축적으로 서술하는 반면, 수학 웹 페이지(포럼, 교육 사이트 등)는 풀이 과정을 상세히 설명하는 경우가 많아 모델의 추론 능력 학습에 더 적합하다.

2 핵심 기여 (Contribution)


DeepSeekMath의 3대 기여

1. **초대형 고품질 수학 코퍼스 구축 (DeepSeekMath Corpus):** Common Crawl에서 고품질 수학 웹 페이지를 식별하는 반복적(iterative) 데이터 선택 파이프라인을 고안하여, 기존 수학 코퍼스(OpenWebMath) 대비 **9배** 크기인 120B 토큰 규모의 데이터를 확보하였다.
2. **코드 사전 학습의 수학적 추론 효과 규명:** 수학 데이터 학습 이전에 코드 데이터를 먼저 학습하는 것이 외부 도구(Tool) 사용 능력뿐만 아니라, **도구 없는(Tool-free)** 수학적 추론 능력도 향상시킴을 실험적으로 증명하였다.
3. **GRPO (Group Relative Policy Optimization) 제안:** 기존 PPO에서 막대한 메모리를 차지하던 가치 모델을 제거하고, 동일 질문에 대한 여러 출력 그룹의 **상대적 점수**로 베이스라인을 추정하는 효율적인 강화학습 알고리즘을 제안하였다.

3 방법론

3.1 데이터 파이프라인

OpenWebMath를 시드 코퍼스(Seed corpus)로 하여 fastText 기반 분류기를 학습시키고, Common Crawl에서 수학 관련 웹 페이지를 추출, 교차 검증 및 필터링하는 과정을 **4차례 반복**하여 고품질의 다국어 수학 데이터셋을 구축하였다.



왜 반복적(iterative) 선택인가?

1회 분류만으로는 Common Crawl의 방대한 데이터에서 수학 관련 페이지를 충분히 식별하기 어렵다. 각 반복마다 새로 발견된 고품질 데이터가 다음 분류기의 학습 데이터에 추가되어 분류 정확도가 점진적으로 향상된다. 이 “눈덩이(snowball)” 방식을 통해 기존 OpenWebMath(13.6B) 대비 **9배** 규모의 코퍼스를 확보할 수 있었다.

3.2 GRPO 최적화 알고리즘

기존 PPO의 복잡한 가치 모델 의존성을 없애기 위해, GRPO는 각 질문 q 에 대해 이전 정책 모델 $\pi_{\theta_{\text{old}}}$ 에서 G 개의 출력 그룹 $\{o_1, o_2, \dots, o_G\}$ 를 샘플링하고, 각 출력에 대한 보상을 계산하여 그룹 내 상대적 이점(Advantage) $\hat{A}_{i,t}$ 를 추정한다.

3.2.1 GRPO 학습 루프

GRPO 알고리즘 단계별 절차

각 학습 이터레이션에서 다음을 수행한다:

1. **그룹 샘플링**: 질문 q 에 대해 이전 정책 $\pi_{\theta_{\text{old}}}$ 로부터 G 개의 완전한 출력 $\{o_1, \dots, o_G\}$ 를 생성한다.
2. **보상 계산**: 각 출력 o_i 에 대해 보상 r_i 를 산출한다 (예: 최종 답이 정답이면 $r_i = 1$, 오답이면 $r_i = 0$).
3. **그룹 상대 Advantage 계산**: 그룹 내 보상의 평균 μ 와 표준편차 σ 로 정규화한다:

$$\hat{A}_{i,t} = \frac{r_i - \mu}{\sigma}, \quad \mu = \frac{1}{G} \sum_{j=1}^G r_j, \quad \sigma = \sqrt{\frac{1}{G} \sum_{j=1}^G (r_j - \mu)^2}$$


핵심: 동일한 $\hat{A}_i$ 값이 출력 o_i 의 모든 토큰 t 에 동일하게 적용된다 (outcome-level 보상).

4. **정책 업데이트**: 아래의 GRPO 목적 함수를 최대화하도록 θ 를 갱신한다.

Outcome-level 보상 vs Process-level 보상

GRPO는 **outcome-supervised RL**에 해당한다: 최종 답의 정오만으로 보상이 결정되며, 중간 추론 단계에 대한 별도 피드백은 없다. 따라서 $\hat{A}_{i,t}$ 는 토큰 위치 t 에 무관하게 동일한 값이다. 이는 구현이 단순하고 보상 함수 설계가 쉽다는 장점이 있지만, “올바른 중간 과정 + 잘못된 최종 답”인 출력도 전체적으로 페널티를 받는 한계가 있다. 이 한계를 극복하기 위해 논문은 Future Work로 **Process Reward Model**(단계별 보상)을 제안하였다.

3.2.2 PPO와의 구조적 비교



3.2.3 GRPO 목적 함수

GRPO는 다음의 목적 함수를 최대화하도록 정책 모델을 훈련한다:

$$J_{\text{GRPO}}(\theta) = \mathbb{E}_{q \sim P(Q), \{o_i\}_{i=1}^G \sim \pi_{\theta_{\text{old}}}(\cdot|q)} \left[\frac{1}{G} \sum_{i=1}^G \frac{1}{|o_i|} \sum_{t=1}^{|o_i|} \left[\min \left(r_{i,t}(\theta) \hat{A}_{i,t}, \text{clip}(r_{i,t}(\theta), 1-\epsilon, 1+\epsilon) \hat{A}_{i,t} \right) - \beta \mathbb{D}_{\text{KL}}[\pi_{\theta} \parallel \pi_{\text{ref}}] \right] \right] \quad (1)$$

여기서 확률비(probability ratio)는 다음과 같다:

$$r_{i,t}(\theta) = \frac{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta_{\text{old}}}(o_{i,t} \mid q, o_{i,<t})}$$

GRPO 목적 함수의 각 항 해설

- $r_{i,t}(\theta) \hat{A}_{i,t}$: 정책 업데이트의 방향과 크기를 결정한다. Advantage가 양수인 출력은 확률을 높이고, 음수인 출력은 확률을 낮춘다.
- $\text{clip}(\cdot, 1-\epsilon, 1+\epsilon)$: PPO에서 차용한 클리핑으로, 정책이 한 번에 너무 크게 변하는 것을 방지하여 훈련 안정성을 확보한다.
- $\beta \mathbb{D}_{\text{KL}}[\pi_{\theta} \parallel \pi_{\text{ref}}]$: 정책 모델이 기준 모델(reference model)에서 지나치게 벗어나지 않도록 제약하는 KL 페널티이다.
- $\frac{1}{|o_i|}$: 출력 길이로 정규화하여 긴 출력이 과도한 영향을 미치는 것을 방지한다.

KL 발산은 보상에 추가하는 대신, 기준 모델 π_{ref} 와 정책 모델 π_{θ} 간의 KL 발산을 손실 함수에 직접 적용하며, 양수가 보장되는 비편향 추정량(unbiased estimator)을 활용한다:

$$\mathbb{D}_{\text{KL}}[\pi_{\theta} \parallel \pi_{\text{ref}}] = \frac{\pi_{\text{ref}}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})} - \log \frac{\pi_{\text{ref}}(o_{i,t} \mid q, o_{i,<t})}{\pi_{\theta}(o_{i,t} \mid q, o_{i,<t})} - 1$$

왜 Critic 모델을 제거할 수 있는가?

PPO에서 Critic 모델 $V_\phi(s_t)$ 는 상태의 기대 보상을 추정하여 Advantage $\hat{A}_t = R_t - V_\phi(s_t)$ 를 계산하는 역할을 한다. GRPO는 이를 그룹 내 상대 비교로 대체한다: 동일 질문에 대해 G 개의 출력을 생성하고, 각 보상 r_i 를 그룹 평균과 표준편차로 정규화하여 $\hat{A}_i = (r_i - \mu)/\sigma$ 를 얻는다. 이 방식은 별도의 가치 모델 없이도 어떤 출력이 상대적으로 좋은지를 판별할 수 있으며, 7B 모델 기준으로 Critic 모델에 필요한 메모리(약 7B 파라미터분)를 완전히 절약한다.

3.2.4 보상 함수 설계

수학 문제에서 보상 함수는 결과 기반(outcome-based)으로 설계된다. 모델이 생성한 최종 답을 정답과 비교하여:

$$r_i = \begin{cases} 1 & \text{최종 답이 정답과 일치} \\ 0 & \text{최종 답이 오답} \end{cases}$$

이 단순한 이진 보상만으로도 그룹 내 상대 비교를 통해 효과적인 학습 신호가 생성된다. 예를 들어 $G = 64$ 개 출력 중 10개가 정답이면, 정답 출력은 양의 Advantage를, 오답 출력은 음의 Advantage를 받아 정책이 올바른 추론 경로를 강화하게 된다.

GRPO 학습 시 모델 구성 비교

구성 요소	PPO	GRPO
Policy Model π_θ	✓	✓
Reference Model π_{ref}	✓	✓
Reward Model	✓	✓
Critic/Value Model V_ϕ	✓	×
총 모델 수	4개	3개

7B 모델 기준, Critic 제거로 약 14GB 이상의 GPU 메모리를 절약할 수 있다.

4 실험 결과

4.1 주요 벤치마크 성능

모델	크기	MATH (%)	GSM8K (%)
Qwen	72B	35.2	—
MetaMath	70B	26.6	—
Gemini Pro	—	32.6	86.5
Inflection-2	—	34.8	81.4
Minerva	540B	33.6	—
Llemma	34B	25.3	—
DeepSeekMath-Base	7B	36.2	—
DeepSeekMath-Instruct	7B	46.8	—
DeepSeekMath-RL	7B	51.7	88.2
+ Self-consistency (64)	7B	60.9	—

핵심 실험 수치

- **MATH 51.7%**: 외부 톨과 보팅 없이 Top-1 정확도 51.7%를 달성하여 Instruct 모델(46.8%) 대비 큰 성능 향상을 이루었다. Self-consistency 적용 시 **60.9%**까지 상승하였다.
- **GSM8K 88.2%**: Gemini Pro(86.5%), Inflection-2(81.4%)를 상회하였다.
- **크기 대비 효율**: 7B 모델이 크기가 최대 10배인 70B급 오픈소스 모델(Qwen 72B, MetaMath 70B)과 파라미터 77배인 Minerva 540B를 모두 능가하였다.

4.2 사전 학습 코퍼스 품질 비교


DeepSeek-LLM 1.3B 기반 사전학습 평가 결과:

코퍼스	토큰 수	MATH (%)
MathPile	–	3.3
OpenWebMath	13.6B	8.9
Proof-Pile-2	–	11.2
DeepSeekMath Corpus	120.2B	13.6

5 한계 및 Future Work

- **기하학·정리 증명의 취약성**: 양적 수학 추론(quantitative reasoning)에는 강하지만, 기하학(geometry)과 정리-증명(theorem-proof) 측면에서는 비공개 모델보다 취약하다. 삼각형이나 타원 등과 관련된 문제를 잘 다루지 못하는 **데이터 선택 편향(data selection bias)**이 관찰되었다.
- **Few-shot 제약**: 파라미터 스케일(7B)의 한계로 인해 GPT-4와 달리 few-shot 프롬프트의 성능 향상 폭이 적고, zero-shot 결과와 비슷한 수준에 머무른다.
- **데이터 파이프라인 고도화**: 사전 학습용 코퍼스 확보를 위해 데이터 선택 파이프라인을 더욱 정교하게 발전시킬 계획이다.
- **향상된 강화학습**: Out-of-distribution 질문과 트리 기반 탐색 디코딩을 위한 강화학습 파이프라인 도입을 제시하였다.
- **Weak-to-strong 정렬**: 노이즈가 섞인 보상 함수에서도 동작하는 정렬 학습법을 제안하였다.
- **Process Reward Model**: 추론 과정별 세분화된 훈련 신호를 주는 Process Reward Model 적용을 추가 연구로 제시하였다.

Summary



전체 흐름 요약

DeepSeekMath는 Common Crawl에서 반복적 선택으로 구축한 120B 토큰 수학 코퍼스와 코드 사전 학습을 통해 강력한 Base 모델을 확보하고, Critic 모델 없이 그룹 상대 비교로 Advantage를 추정하는 **GRPO** 강화학습을 적용하여, 7B 크기로 MATH 51.7%, GSM8K 88.2%를 달성하였다. 이는 70B급 오픈소스 모델과 540B급 폐쇄형 모델을 능가하는 결과이다.