

Scaling Laws for Reward Model Overoptimization

보상 모델 과최적화의 스케일링 법칙 – Goodhart’s Law의 정량적 분석

HAI 논문리딩반

Contents

1	연구 배경 및 문제 정의	2
2	핵심 기여 (Contribution)	2
3	방법론	2
3.1	실험 환경	2
3.2	거리 지표 정의	3
3.3	Best-of- n (BoN) 샘플링의 Gold RM 점수 함수	3
3.4	강화학습(RL – PPO)의 Gold RM 점수 함수	3
3.5	계수의 스케일링	4
4	실험 결과	4
4.1	예측 모델 검증	4
4.2	데이터 크기 스케일링	4
4.3	최적화 효율성: RL vs BoN	4
4.4	정책(Policy) 크기 의존성	4
4.5	KL 페널티의 무효성	5
4.6	RM 앙상블의 효과	5
5	한계 및 Future Work	5
5.1	한계점	5
5.2	Future Work	5
6	Summary	6

1 연구 배경 및 문제 정의

인간 피드백 기반 강화학습(RLHF)에서는 인간의 선호를 예측하도록 학습된 보상 모델(**Proxy Reward Model**)을 최적화의 목표로 사용한다. RLHF 파이프라인은 (1) 사전학습된 LM을 SFT로 미세조정, (2) 인간 비교 데이터로 보상 모델 학습, (3) RL(PPO)로 보상 모델 점수를 최대화하는 3단계로 구성되는데, 본 논문은 **3단계에서 발생하는 과최적화 문제**에 집중한다.

보상 모델은 불완전한 대리 지표(Proxy)이므로, 이를 과도하게 최적화하면 원래 의도했던 실제 목표(Ground truth performance)가 오히려 저하되는 현상이 발생한다.

굿하트의 법칙 (Goodhart's Law)

“어떤 측정 지표가 목표가 되는 순간, 그것은 더 이상 좋은 측정 지표가 아니다.”

Goodhart's law는 4가지 유형으로 분류된다:

1. **Regressional**: Proxy와 True objective 간의 불완전한 상관관계로 인한 괴리 (본 논문의 주요 대상)
2. **Extremal**: 분포의 극단값에서 Proxy-True 관계가 붕괴
3. **Causal**: Proxy를 직접 조작하여 True objective 없이 점수만 올리는 경우
4. **Adversarial**: 에이전트가 의도적으로 Proxy의 약점을 공략

RLHF 맥락에서 이는 다음을 의미한다:

- Proxy RM을 과도하게 최적화하면, Proxy 점수는 계속 상승하지만
- 실제 인간 선호도(Gold RM 점수)는 어느 시점 이후 **하락**한다.

기존 연구의 한계

- 대규모 인간 선호도 데이터를 수집하는 데 드는 **막대한 비용**
- 작은 효과 크기(effect size)로 인한 정밀 측정의 어려움
- 과최적화 현상이 얼마나 발생하고 어떻게 확장(Scaling)되는지 정량적으로 알려진 바가 없음

2 핵심 기여 (Contribution)

3가지 핵심 기여

1. **합성 데이터 셋업 도입**: 인간 라벨러 대신 고정된 강력한 Gold-standard RM(6B)을 사용하여 정답 라벨을 제공하는 합성(Synthetic) 환경을 구축 → 대규모 실험 비용 문제 해결
2. **스케일링 법칙 발견**: 초기 정책과 최적화된 정책 간의 KL 발산을 기준으로, 최적화 방식(BoN, RL)에 따라 실제 보상이 어떻게 변하는지 예측하는 함수 형태(Functional forms)를 경험적으로 발견 및 검증
3. **계수의 스케일링 규명**: 함수 내 계수들이 보상 모델의 매개변수 수에 따라 **로그 함수 형태**로 부드럽게 스케일링됨을 규명

3 방법론

3.1 실험 환경

- **아키텍처**: InstructGPT 설정 및 GPT-3 아키텍처 사용

- **Gold RM:** 6B 매개변수 모델 (고정, Ground truth 역할)
- **Proxy RM:** 3M ~ 3B 매개변수 크기로 다양하게 학습
- **학습 데이터:** Gold RM 점수가 높은 궤적 (trajectory) 을 선호하는 방식으로 100,000 개의 합성 비교 (Synthetic comparisons) 데이터를 확정적으로 생성

3.2 거리 지표 정의

정책 π_{init} 와 최적화된 정책 π 간의 거리를 다음과 같이 정의한다:

KL 기반 이차 거리 지표

$$d := \sqrt{D_{\text{KL}}(\pi \parallel \pi_{\text{init}})}$$

여기서 D_{KL} 은 KL 발산(Kullback-Leibler Divergence)이다. 제곱근을 취함으로써 거리 지표로서의 성질(삼각부등식 근사)을 확보하고, 이후 스케일링 법칙의 함수 형태를 단순화한다.

3.3 Best-of- n (BoN) 샘플링의 Gold RM 점수 함수

Best-of- n 샘플링은 초기 정책 π_{init} 에서 n 개의 응답을 생성한 뒤, Proxy RM 점수가 가장 높은 1 개를 선택하는 방식이다. 이때 KL 발산은 다음과 같이 근사된다:

$$D_{\text{KL}}(\pi_{\text{bon}} \parallel \pi_{\text{init}}) \approx \log n - \frac{n-1}{n}$$

따라서 $d = \sqrt{D_{\text{KL}}} \approx \sqrt{\log n}$ 으로, n 이 기하급수적으로 증가해도 d 는 완만하게 증가한다. Gold RM 점수는 d 에 대해 다음 함수를 따른다:

$$R_{\text{bon}}(d) = d(\alpha_{\text{bon}} - \beta_{\text{bon}} d)$$

- α_{bon} : 초기 최적화 이득률 (선형 상승 기울기)
- β_{bon} : 과최적화로 인한 감쇠 계수 (이차 하락)
- $R(0) := 0$ (최적화 없을 때 기준점)

BoN 함수의 직관

d 가 작을 때는 $\alpha_{\text{bon}} \cdot d$ 항이 지배적이어서 Gold 점수가 선형으로 상승한다. 그러나 d 가 커지면 $\beta_{\text{bon}} \cdot d^2$ 항이 커져 Gold 점수가 하락하기 시작한다. 최적점은 $d^* = \frac{\alpha_{\text{bon}}}{2\beta_{\text{bon}}}$ 에서 달성된다.

3.4 강화학습(RL - PPO)의 Gold RM 점수 함수

$$R_{\text{RL}}(d) = d(\alpha_{\text{RL}} - \beta_{\text{RL}} \log d)$$

- α_{RL} : 초기 최적화 이득률
- β_{RL} : 로그 스케일 감쇠 계수
- BoN과 달리 $\log d$ 항이 포함되어, 과최적화가 더 점진적으로 발생

BoN vs RL 함수 형태의 차이

- **BoN:** 이차 함수적 하락 ($\beta \cdot d^2$) $\rightarrow$ 과최적화가 급격히 발생
- **RL:** 로그 함수적 하락 ($\beta \cdot d \log d$) $\rightarrow$ 과최적화가 완만하게 발생
- 이 차이는 RL이 정책을 점진적으로 업데이트하는 반면, BoN은 고정 분포에서 극단값을 선택하기 때문

3.5 계수의 스케일링

$\alpha_{\text{bon}}, \beta_{\text{bon}}, \alpha_{\text{RL}}, \beta_{\text{RL}}$ 모두 Proxy RM의 매개변수 수 N 에 대해 다음과 같이 스케일링된다:

$$\alpha \propto \log N, \quad \beta \propto \log N$$

두 계수 모두 $\log N$ 에 비례하여 증가하지만, α 의 증가율이 β 보다 크다. 이로 인해 최적점 $d^* = \frac{\alpha}{2\beta}$ (BoN의 경우)가 모델 크기에 따라 점점 멀어지며, 더 넓은 범위에서 과최적화 없이 안전하게 최적화할 수 있다.

스케일링의 실질적 의미

Proxy RM을 더 크게 만들면:

- 초기 이득률(α)이 증가하여 같은 d 에서 더 높은 Gold 점수를 달성
- 과최적화 시작점(d^*)이 더 멀어져 안전한 최적화 범위가 확장
- 그러나 과최적화 자체가 사라지는 것은 아님 — 충분히 최적화하면 여전히 발생

4 실험 결과

4.1 예측 모델 검증

사전 예측(Advance Prediction) 성공

BoN 함수의 경우, $n = 1,000$ (KL 거리 ≈ 6 nats)까지의 데이터만으로 도출된 함수 형태를 통해, 한 번도 보지 않은 $n = 60,000$ (KL 거리 ≈ 10 nats)까지의 실험 결과를 성공적으로 사전 예측하였다.

4.2 데이터 크기 스케일링

- Proxy RM 데이터 크기가 **2,000개 미만**일 때: 무작위 예측 수준의 손실(loss) 대비 개선이 거의 없음
- 임계치를 넘어서면: 데이터가 많아질수록 과최적화가 감소하고 최종 Gold 점수가 향상됨

4.3 최적화 효율성: RL vs BoN

비교 항목	BoN	RL (PPO)
KL 거리 증가 패턴	$\approx \log n$	이차 함수적 (step 기준)
KL 효율성	높음	낮음
과최적화 형태	급격한 이차 하락	완만한 로그 하락

RL의 KL 비효율성에 대한 해석

RL(PPO)은 매 스텝마다 정책을 업데이트하면서 KL 거리를 이차 함수적으로 소모한다. 이는 RL이 동일한 Gold 점수 향상을 달성하기 위해 BoN보다 훨씬 더 많은 “정책 이동 예산”을 사용함을 의미한다. 따라서 RL 환경에서는 조기 종료(early stopping)가 더욱 중요하다.

4.4 정책(Policy) 크기 의존성

정책 모델 크기를 1.2B에서 6B로 늘렸을 때:

- 최적화를 통해 얻는 보상 향상폭은 줄어듦
- 그러나 과최적화의 정도(Proxy-Gold 격차)나 최대 Gold 점수에 도달하는 KL 거리는 거의 동일하게 유지됨

4.5 KL 페널티의 무효성

KL 페널티 실험 결과

RL 환경에서 다양한 KL 페널티 ($\beta_{KL} = 0.01, 0.05, 0.1, 0.5$)를 부여하더라도:

- Gold RM 점수와 KL 거리 간의 프론티어(frontier)는 개선되지 않음
- 단순히 학습을 일찍 종료(early stopping)시키는 것과 동일한 효과만 발생

이는 KL 페널티가 과최적화를 근본적으로 해결하지 못하며, 단지 최적화 속도를 늦출 뿐임을 시사한다.

4.6 RM 앙상블의 효과

RM 앙상블 실험 결과

여러 Proxy RM의 점수를 평균하여 최적화 목표로 사용하는 앙상블 기법을 실험한 결과:

- 앙상블은 단일 RM 대비 과최적화를 유의미하게 완화함
- 동일한 KL 거리에서 더 높은 Gold 점수를 달성 (프론티어 개선)
- 이는 KL 페널티와 달리, 앙상블이 Proxy의 개별 편향(bias)을 상쇄하여 보다 정확한 보상 신호를 제공하기 때문

KL 페널티가 “속도 제한”에 불과한 반면, RM 앙상블은 “더 나은 지도”를 제공하는 셈이다.

5 한계 및 Future Work


5.1 한계점

- 실험이 합성 데이터(Synthetic Data) 환경에서 진행됨
- 실제 인간의 의도(Human intent)와 Ground truth 라벨 간의 불일치로 인해 발생하는 근본적인 과최적화 문제는 반영되지 않음

5.2 Future Work

- InstructGPT 외의 다른 환경에서의 일반화 여부 검증
- 합성 데이터 환경에서 관찰된 보상 모델 간 상관관계가 현실 세계에 그대로 적용되는지 확인
- 보상 모델(RM)을 과최적화에 대해 더욱 강건(robust)하게 만드는 기법 탐구
- Decision Transformers나 Beam search와 같은 다른 형태의 최적화 압력 방식 및 그 차이점 분류 연구
- Proxy RM 점수의 행동 양식을 예측하는 더 정교한 수학적 함수 형태(Functional form) 모델링
- AI 시스템이 고도화될 때 발생 가능한 적대적 굿하트(Adversarial Goodhart) 현상에 대한 실증적 탐구

6 Summary



d 증가 $\rightarrow$ Gold 점수 $\uparrow$ 후 $\downarrow$ (과최적화)

전체 흐름 요약

1. 고정된 Gold RM(6B)을 Ground truth로 사용하는 합성 실험 환경 구축
2. 다양한 크기의 Proxy RM을 학습하고, BoN/RL로 정책을 최적화
3. KL 거리 d 에 대한 Gold 점수의 함수 형태를 경험적으로 도출:
 - BoN: $R(d) = d(\alpha - \beta d)$ (이차 하락)
 - RL: $R(d) = d(\alpha - \beta \log d)$ (로그 하락)
4. 계수 α, β 는 Proxy RM 크기에 대해 $\log N$ 으로 스케일링
5. KL 페널티는 프론티어를 개선하지 못하며, early stopping과 동일한 효과
6. RM 앙상블은 프론티어를 실질적으로 개선하는 유효한 완화 기법